

Apprentissage statistique

Chapitre 7 : Vitesses rapides

Lucie Le Briquer

13 mars 2018

Table des matières

1	Hypothèse de bruit de Massart	2
2	Hypothèse de bruit de Tsybakov	4

1 Hypothèse de bruit de Massart

Définition 1 (bruit de Massart)

Le bruit dans la classification binaire satisfait l'hypothèse de Massart au niveau $\gamma \in]0, \frac{1}{2}]$ si :

$$\forall x \in \mathcal{X}, \left| \eta(x) - \frac{1}{2} \right| \geq \gamma$$

Rappels 1 (inégalité de Bernstein)

Si les $X_i \leq a$ et $\text{Var}(X_i) = \sigma^2$, alors :

$$\mathbb{P}(\overline{X_n} - \mathbb{E}[X] \geq \varepsilon) \leq \exp\left(-\frac{n\varepsilon^2}{2\sigma^2 + \frac{2}{3}\varepsilon a}\right)$$

Théorème 1

Supposons que \mathcal{F} est finie et que $f^* \in \mathcal{F}$ (où f^* est le classifieur optimal de Bayes) alors, sous l'hypothèse de Massart au niveau γ ,

$$\forall \delta > 0, \quad \mathcal{R}(\hat{f}_{\text{ERM}}) - \mathcal{R}^* \leq \frac{\log\left(\frac{|\mathcal{F}|}{\delta}\right)}{n\gamma}$$

avec probabilité au moins $1 - \delta$.

Remarque. L'hypothèse $f^* \in \mathcal{F}$ est nécessaire. Contre-exemple : $\mathcal{X} = \{x_1, x_2\}$ et $\eta(x_1) = 1$, $\eta(x_2) = 0$ mais $\mathcal{F} = \{(0, 0), (1, 1)\}$. Notons $p = \mathbb{P}(X = x_1)$. Alors :

$$\mathcal{R}(0, 0) = p \quad \mathcal{R}(1, 1) = 1 - p$$

Le classifieur optimal minimise $\{p, 1 - p\}$. Donc $(0, 0)$ est optimal si $p < 1 - p \Leftrightarrow p < \frac{1}{2}$ et $(1, 1)$ l'est si $p \geq \frac{1}{2}$.

Donc pour distinguer le classifieur optimal, il faut au moins $\frac{1}{|1-2p|^2}$ échantillons. D'où si $|1-2p| \leq \frac{1}{\sqrt{n}}$, on va sélectionner le mauvais classifieur avec une probabilité constante. L'erreur est de l'ordre de $\frac{1}{\sqrt{n}}$. On a donc une vitesse lente.

Preuve.

$$\begin{aligned} \mathcal{R}(\hat{f}) - \mathcal{R}(f^*) &= \mathcal{R}(\hat{f}) - \hat{\mathcal{R}}_n(\hat{f}) + \underbrace{\hat{\mathcal{R}}_n(\hat{f}) - \hat{\mathcal{R}}_n(f^*)}_{\leq 0} + \hat{\mathcal{R}}_n(f^*) - \mathcal{R}(f^*) \\ &\leq [\hat{\mathcal{R}}_n(f^*) - \hat{\mathcal{R}}_n(\hat{f})] - [\mathcal{R}(f^*) - \mathcal{R}(\hat{f})] \end{aligned}$$

Or,

$$\hat{\mathcal{R}}_n(f^*) - \hat{\mathcal{R}}_n(\hat{f}) = \frac{1}{n} \sum_{i=1}^n \underbrace{(\mathbb{1}_{f^*(x_i) \neq y_i} - \mathbb{1}_{\hat{f}(x_i) \neq y_i})}_{Z_i(\hat{f})}$$

Notons $Z_i(f) = \mathbb{1}_{f^*(x_i) \neq y_i} - \mathbb{1}_{f(x_i) \neq y_i}$. Il suffit alors de montrer que $\forall f \in \mathcal{F}$,

$$\frac{1}{n} \sum_{i=1}^n Z_i(f) - \mathbb{E}[Z_i(f)] \leq \frac{\log\left(\frac{M}{\delta}\right)}{\gamma n}$$

avec probabilité $\geq 1 - \delta$ (en notant $M = |\mathcal{F}|$).

On va utiliser l'inégalité de Bernstein. Pour ce faire, on calcule :

$$\text{Var}(Z_i(f)) \leq \mathbb{E}[Z_i^2(f)] = \mathbb{P}(f(x_i) \neq f^*(x_i)) = \sigma_f^2$$

En utilisant Bernstein, en notant :

$$\varepsilon(f) := \max\left(\sqrt{\frac{2\sigma_f^2 \log\left(\frac{M}{\delta}\right)}{n}}; \frac{2 \log\left(\frac{M}{\delta}\right)}{3n}\right)$$

On obtient avec une probabilité $\geq 1 - \delta$, $\forall f \in \mathcal{F}$:

$$\frac{1}{n} \sum_{i=1}^n Z_i(f) - \mathbb{E}[Z_i(f)] \leq \varepsilon(f)$$

Donc en particulier,

$$\mathcal{R}(\hat{f}) - \mathcal{R}(f^*) \leq \varepsilon(\hat{f})$$

On va utiliser l'hypothèse de bruit pour borner σ_f^2 . On va montrer que $\mathcal{R}(f) - \mathcal{R}(f^*) \geq 2\gamma\sigma_f^2$.
On sait que :

$$\mathcal{R}(f) - \mathcal{R}(f^*) = \mathbb{E}\left[2\left|\frac{1}{2} - \eta(x)\right| \mathbb{1}_{f(x) \neq f^*(x)}\right] \geq 2\gamma\mathbb{P}(f(x) \neq f^*(x)) = 2\gamma\sigma_f^2 \quad (*)$$

Donc,

$$\mathcal{R}(\hat{f}) - \mathcal{R}(f^*) \leq \max\left(\sqrt{\frac{2\sigma_f^2 \log\left(\frac{M}{\delta}\right)}{n}}; \frac{2 \log\left(\frac{M}{\delta}\right)}{3n}\right)$$

et

$$\sigma_f^2 \leq \frac{\mathcal{R}(\hat{f}) - \mathcal{R}(f^*)}{2\gamma}$$

Donc finalement,

$$\mathcal{R}(\hat{f}) - \mathcal{R}(f^*) \leq \frac{\log\left(\frac{M}{\delta}\right)}{\gamma n}$$

□

2 Hypothèse de bruit de Tsybakov

Définition 2 (α -marge de Tsybakov)

L'hypothèse de α -marge de Tsybakov est lorsqu'il existe $c_0 > 0$ et $\varepsilon_0 > 0$ tels que :

$$\mathbb{P} \left(\left| \eta(x) - \frac{1}{2} \right| \leq \varepsilon \right) \leq c_0 \varepsilon^{\frac{\alpha}{1-\alpha}}$$

pour tout $\varepsilon < \varepsilon_0$.

Remarque. Si $\alpha = 0$ la condition est vide. Si $\alpha = 1$, la condition est celle de Massart.

Théorème 2

Sous la condition de α -marge et $f^* \in \mathcal{F}$, on a avec probabilité $\geq 1 - \delta$:

$$\mathcal{R}(\hat{f}) - \mathcal{R}(f) \leq c \left(\frac{\log \left(\frac{M}{\delta} \right)}{n} \right)^{\frac{1}{2-\alpha}}$$

où c est une constante qui ne dépend que de c_0 , ε_0 et α .

Preuve.

La preuve est identique à celle de Massart jusqu'à (*).

$$\begin{aligned} \mathcal{R}(f) - \mathcal{R}(f^*) &= \mathbb{E} \left[2 \left| \frac{1}{2} - \eta(x) \right| \mathbb{1}_{f(x) \neq f^*(x)} \right] \\ &\geq \mathbb{E} \left[2 \left| \frac{1}{2} - \eta(x) \right| \mathbb{1}_{f(x) \neq f^*(x)} \mathbb{1}_{\left| \frac{1}{2} - \eta(x) \right| \geq t} \right] \\ &\geq 2t \mathbb{P} \left(f(x) \neq f^*(x) \text{ et } \left| \frac{1}{2} - \eta(x) \right| \geq t \right) \\ &\geq 2t \mathbb{P}(f(x) \neq f^*(x)) - 2t \mathbb{P} \left(\left| \frac{1}{2} - \eta(x) \right| \leq t \right) \text{ car } \mathbb{P}(A \cap B) \geq \mathbb{P}(A) - \mathbb{P}(B^C) \\ &\geq 2t \sigma_f^2 - 2tc_0 t^{\frac{\alpha}{1-\alpha}} \quad \text{si } t \leq \varepsilon_0 \end{aligned}$$

En prenant $t = c_1 \sigma_f^2 \frac{1-\alpha}{\alpha}$, avec c_1 tel que $t \leq \varepsilon_0$, on obtient :

$$\mathcal{R}(f) - \mathcal{R}(f^*) \geq c_2 \sigma_f^{2^{1+\frac{1-\alpha}{\alpha}}} = c_2 \sigma_f^{\frac{2}{\alpha}}$$

Ainsi,

$$\mathcal{R}(\hat{f}) - \mathcal{R}(f^*) \leq \max \left(\sqrt{\frac{2 \left(\mathcal{R}(\hat{f}) - \mathcal{R}(f^*) \right)^\alpha \log \left(\frac{M}{\delta} \right)}{c_2^\alpha n}} ; \frac{2 \log \left(\frac{M}{\delta} \right)}{3n} \right)$$

D'où :

$$\mathcal{R}(\hat{f}) - \mathcal{R}(f^*) \leq c_3 \left(\frac{\log \left(\frac{M}{\delta} \right)}{n} \right)^{\frac{1}{2-\alpha}}$$

□