

# Apprentissage statistique

## Chapitre 8 : Convexification du problème binaire

Lucie Le Briquer

13 mars 2018

ERM :

$$\min_{f \in \mathcal{F}} \left[ \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{f(x_i) \neq y_i} \right] = \hat{R}_n(f)$$

- $\mathcal{F}$  peut être finie de très grand cardinalité
- $n$  finie peut être grand

$\hat{\mathcal{R}}_n(f)$  est à valeurs discrètes.

Pour pouvoir résoudre un problème, on cherche à le convexifier. On peut convexifier la perte et/ou convexifier l'ensemble  $\mathcal{F}$ .

1ère étape (convexification de  $\mathcal{F}$ )

Si  $f \in \mathcal{F}: \mathcal{X} \rightarrow \{0, 1\}$ , on les symétrise en  $\tilde{f} = 2f - 1$  à valeurs dans  $\{-1, 1\}$ . Donc on peut supposer  $f \in \mathcal{F}: \mathcal{X} \rightarrow \{-1, 1\}$ . Si  $f$  est à valeurs dans  $\{-1, 1\}$ ,

$$\mathbb{1}_{f(X) \neq Y} \Leftrightarrow \mathbb{1}_{f(X)Y < 0}$$

On va considérer non plus des classifieurs  $\mathcal{X} \rightarrow \{-1, 1\}$ , mais des classifieurs dit *soft* à valeurs dans  $\mathbb{R}$  (ou  $[-1, 1]$ ). À chaque classifieur *soft*  $f: \mathcal{X} \rightarrow \mathbb{R}$ , on associe un classifieur *binaire*  $\text{sgn}(f) \in \{-1, 1\}$ .

**Exemples.**

- linéaire :  $f_a(x) = a^T x$  pour  $a \in \mathcal{A} \subset \mathbb{R}^d$
- majoritaire :

$$f_\lambda(x) = \sum_{i=1}^M \lambda_i f_i(x) \quad \text{pour } (f_1, \dots, f_M) \text{ fixé et } \lambda \in \mathcal{S}^{n-1}$$

- base :

$$f_\theta(x) = \left\{ \sum_{i \in \mathbb{N}} \theta_i f_i(x), \theta_i \in \mathbb{R}^{\mathbb{N}} \text{ et } (f_1, \dots, f_i, \dots) \text{ fixés} \right\}$$

Dorénavant on suppose que l'on a une famille convexe de classifieurs *soft*.

2ème étape (convexifier la perte)

Le problème :

$$\min_{f \in \mathcal{F}_{\text{soft}}} \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{f(X_i)Y_i < 0}$$

n'est pas convexe. On va donc rempaquer  $\mathbb{1}_{-Z \geq 0}$  par une fonction convexe.


**Définition 1** (fonction *surrogate*)

$\varphi$  est une fonction *surrogate* si :

- $\varphi$  est convexe
- $\varphi$  est croissante
- $\varphi(0) = 1, \varphi \geq 0$

**Exemples.**

- Hinge :  $\max(0, x + 1)$



- $\exp : \exp(\eta x)$
- $\log\text{-it} : \log_2(1 + e^{\eta x})$

Au lieu de minimiser le risque empirique, on considère le  $\varphi$ -risque empirique :

$$\hat{\mathcal{R}}_{\varphi}(f) = \frac{1}{n} \sum_{i=1}^n \varphi(-f(X_i)Y_i)$$

et le  $\varphi$ -risque  $\mathcal{R}_{\varphi}(f) = \mathbb{E}[\varphi(-f(X)Y)]$ . On note :

$$f_{\varphi}^* = \underset{f: \mathcal{X} \rightarrow \mathbb{R}}{\operatorname{argmin}} \mathcal{R}_{\varphi}(f) \quad \text{et} \quad \hat{f}_{\varphi} = \underset{f \in \mathcal{F}}{\operatorname{argmin}} \hat{\mathcal{R}}_{\varphi}(f)$$

**Théorème 1**

Si  $\varphi$  est différentiable, alors  $\operatorname{sgn}(f_{\varphi}^*) = f^*$ .

**Preuve.**

$$f^*(x) = 1 \Leftrightarrow \eta(x) \geq \frac{1}{2}$$

$f_{\varphi}^*$  est la fonction qui minimise  $\mathbb{E}[\varphi(-f(X)Y)]$ . On raisonne point par point et :

$$f_{\varphi}^*(x) = \underset{\alpha \in \mathbb{R}}{\operatorname{argmin}} \eta(x)\varphi(-\alpha) + (1 - \eta(x))\varphi(\alpha)$$

Notons  $H_\eta(\alpha) = \eta\varphi(-\alpha) + (1-\eta)\varphi(\alpha)$  alors  $\operatorname{argmin} H_\eta(\alpha)$  est obtenu par :

$$-\eta\varphi'(-\alpha) + (1-\eta)\varphi'(\alpha) = 0 \quad \Leftrightarrow \quad \frac{\eta}{1-\eta} = \frac{\varphi'(\alpha)}{\varphi'(-\alpha)}$$

D'où,

$$\eta \geq \frac{1}{2} \Leftrightarrow \frac{\eta}{1-\eta} \geq 1 \Leftrightarrow \varphi'(\alpha) \geq \varphi'(-\alpha) \stackrel{\text{convexité}}{\Leftrightarrow} \alpha \geq -\alpha \Leftrightarrow \alpha \geq 0$$

Don'  $\eta(x) \geq \frac{1}{2} \Leftrightarrow f_\varphi^*(x) \geq 0$  ou encore,  $f^*(x) = 1 \Leftrightarrow \operatorname{sgn}(f_\varphi^*(x)) = 1$ . □

**Lemme 1** (de Zhang) —

Pour tout  $\eta > 0$ , on note  $\tau(\eta) = \min_{\alpha \in \mathbb{R}} H_\eta(\alpha)$ , supposons qu'il existe  $c > 0$  et  $\gamma < 1$  tels que :

$$\left| \eta - \frac{1}{2} \right| \leq c(1 - \tau(\eta))^\gamma$$

pour tout  $\eta \in [0, 1]$ , alors,

$$\mathcal{R}(\operatorname{sgn}(f)) - \mathcal{R}(f^*) \leq 2c(\mathcal{R}_\varphi(f) - \mathcal{R}_\varphi^*)^\gamma$$

**Preuve.**

$$\begin{aligned} \mathcal{R}(\operatorname{sgn}(f)) - \mathcal{R}(f^*) &= \mathbb{E} \left[ 2 \left| \eta(X) - \frac{1}{2} \right| \mathbb{1}_{\operatorname{sgn}(f)f^* < 0} \right] \\ &\stackrel{\text{hyp}}{\leq} 2c \mathbb{E} \left[ (1 - \tau(\eta(x)))^\gamma \mathbb{1}_{\operatorname{sgn}(f)f^* < 0} \right] \\ &\stackrel{\text{Jensen}}{\leq} 2c \mathbb{E} \left[ 1 - \tau(\eta(x)) \mathbb{1}_{\operatorname{sgn}(f)f^* < 0} \right]^\gamma \end{aligned}$$

Le résultat vient du fait que :

$$\mathcal{R}_\varphi(f) - \mathcal{R}_\varphi^* \geq \mathbb{E} \left[ (1 - \tau(\eta(x))) \mathbb{1}_{\operatorname{sgn}(f)f^* < 0} \right]$$

En effet  $f^*$  a le même signe que  $f_\varphi^*$  et  $\operatorname{sgn}(f)$  a le même signe que  $f$ . Donc :

$$\mathbb{E} \left[ (1 - \tau(\eta(x))) \mathbb{1}_{\operatorname{sgn}(f)f^* < 0} \right] = \mathbb{E} \left[ (1 - \tau(\eta(x))) \mathbb{1}_{f(X)f_\varphi^*(X) < 0} \right]$$

$\mathcal{R}_\varphi(f) = \mathbb{E}[\varphi(-f(X)Y)] = \mathbb{E}[H_{\eta(X)}(f(X))]$  et  $\mathcal{R}_\varphi^* = \mathbb{E}[\min_\alpha H_{\eta(X)}(\alpha)]$ . Donc il suffit de montrer que  $\forall x \in X$ ,

$$H_{\eta(x)}(f(x)) \geq (1 - \tau(\eta(x))) \mathbb{1}_{f(x)f_\varphi^*(x) < 0} + \min_\alpha H_{\eta(x)}(\alpha)$$

Si  $\mathbb{1}_{f(x)f_\varphi^*(x) < 0} = 0$  alors c'est bon. Sinon, supposons que  $f(x)f_\varphi^*(x) < 0$ . On veut donc montrer :

$$H_{\eta(x)}(f(x)) \geq (1 - \tau(\eta(x))) + \tau(\eta(x)) = 1$$

Mais

$$\begin{aligned} H_{\eta(x)}(f(x)) &= \eta(x)\varphi(-f(x)) + (1-\eta(x))\varphi(f(x)) \\ &\geq \varphi(-\eta(x)f(x) + (1-\eta(x))f(x)) \\ &= \varphi((1-2\eta(x))f(x)) \end{aligned}$$

Comme  $f_\varphi^*$  a le même signe que  $f^*$  et  $f^*$  a le même signe que  $2\eta(x) - 1$ . Comme  $f(x)f_\varphi^*(x) < 0$ ,  $\text{sgn}(f_\varphi^*(x)) = -\text{sgn}(f^*) = -\text{sgn}(2\eta(x) - 1) = \text{sgn}(1 - 2\eta(x))$ . Alors  $(1 - 2\eta(x))f(x) \geq 0$  et donc comme  $\varphi$  est croissante et que  $\varphi(0) = 1$ , on a bien  $H_{\eta(x)}(f(x)) \geq 1$ .  $\square$

**Remarque.**

- Si  $\varphi$  est Hinge,  $c = \frac{1}{2}$  et  $\gamma = 1$
- Si  $\varphi$  est exp,  $c = \frac{1}{\sqrt{2}}$  et  $\gamma = \frac{1}{2}$
- Si  $\varphi$  est log-it,  $c = \frac{1}{\sqrt{2}}$  et  $\gamma = \frac{1}{2}$