

Apprentissage statistique

TD2 : Inégalités de concentration

Lucie Le Briquer

5 février 2018

1 TD1

2 Inégalités de concentration

Exercice 2.1

1. X v.a. positive. Comme $t\mathbb{1}_{X \geq t} \leq X$, $\mathbb{P}(X \geq t) \leq t^{-1}\mathbb{E}[X]$.
2. (inégalité de Markov généralité) Y v.a. réelle telle que $\mathbb{P}(Y \in I) = 1$ avec I intervalle de \mathbb{R} . Soit $g: I \rightarrow \mathbb{R}_+$ croissante.

$$\{Y \geq t\} \cap \{Y \in I\} \subset \{g(Y) \geq g(t)\} \cap \{Y \in I\} \quad \text{car } g \text{ croissante sur } I$$

Alors,

$$\mathbb{P}(Y \geq t) = \mathbb{P}(Y \geq t, Y \in I) \leq \mathbb{P}(g(Y) \geq g(t), Y \in I) \leq g^{-1}(t)\mathbb{E}[g(Y)]$$

Exercice 2.2

1. Soit $s > 0$, posons $g_s: x \mapsto \exp(sx)$. Alors, par l'exercice 1,

$$\mathbb{P}(X \geq t) \leq g(t)^{-1}\mathbb{E}[\exp(sX)] \leq \exp(-st) \exp\left(\frac{s^2 b^2}{2}\right)$$

En minimisant en s , on obtient :

$$\mathbb{P}(X \geq t) \leq \exp\left(-\frac{t^2}{2b^2}\right)$$

- 2.

$$\mathbb{E}[\exp(tX)] = \mathbb{E}\left[\sum_{k=0}^{+\infty} \frac{t^k X^k}{k!}\right]$$

Montrons que :

$$\sum_{k=0}^{+\infty} \frac{\mathbb{E}[|X|^k]}{k!} < +\infty$$

On a $|X| \leq e^{|X|} \leq e^X + e^{-X}$. De plus,

$$\sum_{k \geq 0} \frac{\mathbb{E}[|X|^k]}{k!} \stackrel{\text{Beppo-Levy}}{=} \mathbb{E}[e^{|X|}] \leq \mathbb{E}[e^X] + \mathbb{E}[e^{-X}] < +\infty$$

L'interversion somme/intégrale est donc justifiée. Alors,

$$\mathbb{E}[e^{tX}] = 1 + t\mathbb{E}[X] + \frac{t^2}{2}\mathbb{E}[X^2] + t^3\varepsilon_1(t) \leq 1 + \frac{t^2b^2}{2} + t^3\varepsilon_2(t) \quad (*)$$

On a que $t\mathbb{E}[X] \underset{t \sim 0}{\leq} t^2\varepsilon_3(t) \Rightarrow \mathbb{E}[X] = 0$ avec t et $-t$.

De (*), on en déduit :

$$\frac{t^2}{2}\mathbb{E}[X^2] \leq \frac{t^2b^2}{2} + \varepsilon_4(t)t^3$$

En divisant par t puis en prenant la limite on aura $\mathbb{E}[X^2] = \text{Var}(X) \leq b^2$.

Exercice 2.3

1. $S_n = \sum X_i$, avec X_i b_i -sous-gaussienne. Il suffit de montrer que S_n est $\sqrt{\sum b_i^2}$ -sous-gaussienne.

$$\mathbb{E} \left[\exp \left(s \sum_{i=1}^n X_i \right) \right] = \prod_{i=1}^n \mathbb{E}[\exp(sX_i)] = \exp \left(\frac{s^2}{2} \left(\sum_{i=1}^n b_i^2 \right) \right)$$

Ainsi par l'exercice 2,

$$\mathbb{P}(S_n \geq t) \leq \exp \left(-\frac{t^2}{2 \sum_{i=1}^n b_i^2} \right)$$

Comme $-S_n$ est aussi $\sqrt{\sum b_i^2}$, on a comme majoration :

$$\mathbb{P}(|S_n| \geq t) \leq \mathbb{P}(S_n \geq t) + \mathbb{P}(-S_n \geq t) \leq 2 \exp \left(-\frac{t^2}{2 \sum_{i=1}^n b_i^2} \right)$$

2. (X_i) v.a.i.i.d. $\mathcal{N}(0, \sigma^2)$. Alors $\mathbb{E}[e^{tX_i}] = \exp \left(\frac{t^2 \sigma^2}{2} \right)$. Ainsi,

$$\mathbb{P}(|S_n| \geq t) \leq 2 \exp \left(-\frac{t^2}{2n\sigma^2} \right)$$

3. (X_i) v.a.i.i.d. de loi de Rademacher. On a :

$$\mathbb{E}[e^{tX}] = \frac{e^t + e^{-t}}{2} = \text{ch}(t) \leq \exp \left(\frac{t^2}{2} \right)$$

Exercice 2.4

Il suffit de montrer que $\forall i$, X_i est $\frac{M_i - m_i}{2}$ -sous-gaussienne. Soit X v.a. telle que $m \leq X \leq M$, X est $\frac{M-m}{2}$ -sous-gaussienne ? Soit $s \in \mathbb{R}$. On peut décomposer X comme :

$$X = M \frac{X - m}{M - m} + m \frac{M - X}{M - m}$$

$$\exp(sX) \leq \frac{(X - m)e^{sM} + (M - X)e^{sm}}{M - m} \quad \text{par convexité}$$

Ainsi,

$$\mathbb{E}[e^{sX}] \leq \frac{-m}{M - m} e^{sM} + \frac{M}{M - m} e^{sm} \quad \text{car } \mathbb{E}[X] = 0$$

Par passage au log, on obtient :

$$\begin{aligned} \log(\mathbb{E}[e^{sX}]) &\leq \log \left(e^{sm} \left(\frac{M}{M - m} - \frac{m}{M - m} e^{s(M-m)} \right) \right) \\ &\leq sm + \log \left(\frac{M}{M - m} - \frac{m}{M - m} e^{s(M-m)} \right) \\ &= \varphi_p(u) \end{aligned}$$

avec $u = s(M - m)$ et $p = \frac{M}{M-m}$. Or $u \mapsto \varphi_p(u) \in \mathcal{C}^\infty(\mathbb{R}_+)$.

$$\varphi_p'(0) = 0 \quad \varphi_p''(u) = \frac{p(1-p)\exp(u)}{(p + (1-p)\exp u)^2} \leq \frac{1}{4} \quad \forall u \in \mathbb{R}_+$$

Car $\frac{(a+b)^2}{4} = \frac{a^2+b^2}{4} + \frac{ab}{2} \geq ab$.

$$\begin{aligned} \varphi_p(u) &= \varphi_p(0) + \varphi_p'(0)u + \int_0^u (u-v)\varphi_p''(v)dv \\ |\varphi_p(u)| &\leq 0 + 0 + \int_0^u (u-v)\frac{1}{4}dv \\ &\leq \frac{u^2}{8} \quad \forall u \geq 0 \end{aligned}$$

Conclusion : pour tout $s \geq 0$,

$$\mathbb{E}[\exp(sX)] \leq \exp \left(\frac{s^2(M-m)^2}{2} \right)$$

En considérant $-X$, on l'obtient pour tout $x \in \mathbb{R}$, ce qui conclut la preuve.

Exercice 2.5

(X_n) une (\mathcal{F}_n) -martingale. $S_n = \sum_{i=1}^n X_i$. On suppose que :

$$|X_{i+1} - X_i| \leq b_{i+1} < +\infty \quad \mathbb{P} - \text{p.s.}$$

1.

$$\mathbb{E}[\exp(t(Y_{n+1} - Y_n)) | \mathcal{F}_n] \leq \exp(t^2 b_{n+1}^2 / 2) \quad (*)$$

$$\begin{aligned} \mathbb{E}[\exp(t(Y_n - Y_0))] &= \mathbb{E} \left[\exp \left(t \sum_{i=0}^n Z_i \right) \right] \\ &= \mathbb{E} \left[\mathbb{E} \left[\exp \left(t \sum_{i=0}^{n-1} Z_i \right) \mid \mathcal{F}_n \right] \right] \\ &= \mathbb{E} \left[\mathbb{E} \left[\exp \left(t \sum_{i=0}^{n-2} Z_i \right) \right] \mathbb{E}[\exp(tZ_{n-1}) \mid \mathcal{F}_n] \right] \\ &\leq e^{t^2 b_{n+1}^2 / 2} \mathbb{E} \left[\exp \left(t \sum_{i=0}^{n-2} Z_i \right) \right] \quad \text{car } (X_n) \text{ } (\mathcal{F}_n) \text{ - martingale} \end{aligned}$$

où $Z_i = Y_{i+1} - Y_i$. Par récurrence on obtient alors que $S_n = Y_n - Y_0$ est $\sqrt{\sum b_i^2}$ -sous-gaussienne.

2. Il suffit de montrer que (X_n) satisfait (*). On sait que l'on a :

$$|w_n| \leq |X_{n+1} - X_n| \leq b_{n+1} \quad \mathbb{P} - \text{p.s.}$$

Alors,

$$m = -b_{n+1} \leq w_n \leq b_{n+1} = M$$

D'après la preuve de l'inégalité d'Hoeffding, on a $\forall t \in \mathbb{R}$:

$$w_n \leq M \frac{w_n - m}{M - m} + m \frac{M - w_n}{M - m}$$

D'où,

$$\mathbb{E}[\exp(tw_n) \mid \mathcal{F}_n] \leq \frac{e^{tM}}{M - m} \mathbb{E}[w_n - m \mid \mathcal{F}_n] + \frac{e^{tm}}{M - m} \mathbb{E}[M - w_n \mid \mathcal{F}_n]$$

En utilisant $\mathbb{E}[w_n | \mathcal{F}_n] = 0$ car (X_n) est une (\mathcal{F}_n) -martingale, on peut copier la preuve de Hoeffding et conclure que X_n satisfait (*).

Exercice 2.6

1. Soit $(\mathcal{F}_k)_{k \leq n} = (\sigma(X_1, \dots, X_k))_{k \leq n}$ et $\mathcal{F}_i = \mathcal{F}_n$ pour $i > n$. Posons $M_i = \mathbb{E}[f(X_1, \dots, X_n) \mid \mathcal{F}_i]$ pour $i = 0, \dots, n$ et $M_i = f(X_1, \dots, X_n)$ pour $i \geq n+1$. $(M_i)_{i \in \mathbb{N}}$ est une $(\mathcal{F}_i)_{i \in \mathbb{N}}$ -martingale. Il faut vérifier les hypothèses d'Azuma-Hoeffding.

$$|M_{i+1} - M_i| = \left| \mathbb{E}[f(X_1, \dots, X_n) \mid \mathcal{F}_{i+1}] - \mathbb{E}[f(X_1, \dots, X_n) \mid \mathcal{F}_i] \right|$$

Les (X_i) sont indépendants, donc :

$$\mathbb{E}[f(X_1, \dots, X_n) | \mathcal{F}_i] = \psi_i(X_1, \dots, X_i)$$

où $\psi_i(x_1, \dots, x_i) = \mathbb{E}[f(x_1, \dots, x_i, X_{i+1}, \dots, X_n)]$. Donc :

$$\begin{aligned} |M_{i+1} - M_i| &= |\psi_{i+1}(X_1, \dots, X_{i+1}) - \psi_i(X_1, \dots, X_i)| \\ &= |\mathbb{E}[f(x_1, \dots, x_{i+1}, X_{i+2}, \dots, X_n) - f(x_1, \dots, x_i, X_{i+1}, \dots, X_n)]| \\ &\leq b_{i+1} \end{aligned}$$

Conclusion, $|M_{i+1} - M_i| \leq b_{i+1}$ \mathbb{P} -p.s.

2. $(Y_{i,k})_{i \in 1:n, k \in 1:m}$.

$$f(Y_{1,1}, \dots, Y_{n,m}) = g(Z_1^{(m)}, \dots, Z_n^{(m)})$$

avec $Z_i = \frac{1}{\sqrt{m}} \sum_{k=0}^m Y_{i,k}$. Par le TCL en dimension n on a $(Z_1, \dots, Z_n) \rightarrow \mathcal{N}(0, \text{id}_n)$. D'après le théorème du porte-manteau, et comme g est continue, il suffit de montrer que $\forall m \in \mathbb{N}^*$:

$$\mathbb{P}\left(g(Z_1^{(m)}, \dots, Z_n^{(m)}) - \mathbb{E}[g(Z_1^{(m)}, \dots, Z_n^{(m)})] \geq t\right) \leq \exp\left(-\frac{t^2}{2n}\right) \quad (*)$$

Pour montrer (*) pour tout m , on applique Mc Diarmid à $f(Y_{1,1}, \dots, Y_{n,m})$. Comme :

$$|f(y_{1,1}, \dots, y_{i,k}, \dots, y_{n,m}) - f(y_{1,1}, \dots, \tilde{y}_{i,k}, \dots, y_{n,m})| \leq |y_{i,k} - \tilde{y}_{i,k}| \leq \frac{1}{\sqrt{m}}$$

On obtient en appliquant Mc Diarmid :

$$\mathbb{P}\left(g(Z_1^{(m)}, \dots, Z_n^{(m)}) - \mathbb{E}[g()] \geq t\right) \leq \exp\left(-\frac{t^2}{2 \sum_{(i,k) \in \{1, \dots, n\} \times \{1, \dots, m\}} \frac{1}{m}}\right) = \exp\left(-\frac{t^2}{2n}\right)$$

Remarque.

$$\begin{aligned} (X_n) \Rightarrow Z \sim \mathcal{N}(0, \text{id}) &\stackrel{\text{def}}{\Leftrightarrow} \mathbb{E}[h(Y_n)] \rightarrow \mathbb{E}[h(Z)] \quad \forall h \in \mathcal{C}_b(\mathbb{R}^d) \\ &\stackrel{\text{porte-manteau}}{\Leftrightarrow} \mathbb{P}(g(X_n) \leq t) \rightarrow \mathbb{P}(g(Z) \leq t) \quad \forall t \in \mathbb{R} \text{ et } g: \mathbb{R}^d \rightarrow \mathbb{R} \text{ continue} \end{aligned}$$

3 Concepts de base de l'apprentissage statistique : classifieurs et fonctions de perte

Exercice 3.1

1. Soit f un classifieur.

$$\begin{aligned} R_{\mathbb{P}}^{c_\omega}(f) &= \mathbb{E}[c_\omega(Y, f(X))] = \mathbb{E}[\omega_0 \mathbb{1}_{Y=1} \mathbb{1}_{f(X)=0} + \omega_1 \mathbb{1}_{Y=0} \mathbb{1}_{f(X)=1}] \\ &= \mathbb{E}[\omega_0 Y(1 - f(X)) + \omega_1 (1 - Y)f(X)] \\ &= \mathbb{E}\left[\mathbb{E}[\omega_0 Y(1 - f(X)) + \omega_1 (1 - Y)f(X) \mid X]\right] \quad \eta(X) = \mathbb{E}[Y \mid X] \\ &= \mathbb{E}[\omega_0 \eta(X)(1 - f(X)) + \omega_1 (1 - \eta(X))f(X)] \\ &\geq \mathbb{E}[\min(\omega_0 \eta(X)(1 - f(X)), \omega_1 (1 - \eta(X))f(X))] \end{aligned}$$

On a égalité si $f(X) = 1 \Leftrightarrow \omega_1 (1 - \eta(X)) \leq \omega_0 \eta(X) \Leftrightarrow \eta(X) \geq \frac{\omega_1}{\omega_0 + \omega_1}$. Donc

$$f(x) = \mathbb{1}_{\eta(x) \geq \frac{\omega_1}{\omega_0 + \omega_1}}$$

est un classifieur de Bayes.

2. Excès de risque :

$$\begin{aligned}\rho(f, f^*) &= \mathbb{E}[\omega_0 \eta(X)(f^*(X) - f(X)) + \omega_1(1 - \eta(X))(f(X) - f^*(X))] \\ &= \mathbb{E}[\mathbb{1}_{f(X)=0} \mathbb{1}_{f^*(X)=1}(\omega_0 \eta(X) - \omega_1(1 - \eta(X))) \\ &\quad - \mathbb{1}_{f(X)=1} \mathbb{1}_{f^*(X)=0}(\omega_0 \eta(X) - \omega_1(1 - \eta(X)))]\end{aligned}$$

Sur $f^*(X) = 1$, $\omega_0 \eta(X) - \omega_1(1 - \eta(X)) \geq 0$, sur $f^*(X) = 0$, $\omega_0 \eta(X) - \omega_1(1 - \eta(X)) \leq 0$.
D'où :

$$\rho(f, f^*) = (\omega_0 + \omega_1) \mathbb{E} \left[\left| \eta(X) - \frac{\omega_1}{\omega_0 + \omega_1} \right| \mathbb{1}_{f(X) \neq f^*(X)} \right]$$

Si f est un classifieur de Bayes, alors $\rho(f, f^*) = 0$. Donc :

$$f(X) = f^*(X) \text{ sur } \eta(X) \neq \frac{\omega_1}{\omega_0 + \omega_1}$$

4 L'algorithme de perceptron

Exercice 4.1

1. Notons $A = \{i \in \{1, \dots, T\}, \mid \omega_i \neq \omega_{i-1}\}$.

$$\omega_t = \sum_{i \in A} y_i x_i$$

$$\begin{aligned}\langle \omega_t, \omega^* \rangle &= \sum_{i \in A} y_i x_i^T \omega^* \\ &\geq \text{Card}(A) \rho \|\omega^*\| \quad \text{par hypothèse}\end{aligned}$$

Or par Cauchy-Schwarz,

$$|\langle \omega_t, \omega^* \rangle| \leq \|\omega^*\| \|\omega_t\|$$

Comme,

$$\begin{aligned}\|\omega_T\|^2 &= \|\omega_{T-1}\|^2 + \underbrace{2y_T \langle \omega_{T-1}, x_T \rangle \mathbb{1}_{t \in A}}_{\leq 0 \text{ si } t \in A} + \|x_T\|^2 \mathbb{1}_{\{t \in A\}} \\ &\leq \|\omega_{T-1}\|^2 + r^2 \mathbb{1}_{t \in A} \\ &\leq r^2 \text{Card}(A) \quad \text{par récurrence}\end{aligned}$$

On a donc :

$$\rho \|\omega^*\| \text{Card}(A) \leq \|\omega^*\| r \sqrt{\text{Card}(A)}$$